

AI Humanizers 与对抗性文本改写对 AI 文本检测的影响：

系统化文献综述大纲

综述类型	系统性文献综述 (Systematic Literature Review)
研究领域	自然语言处理 (NLP) · AI 安全 (AI Security) · 学术诚信 (Academic Integrity)
目标读者	NLP 与 AI 安全领域研究生及研究人员
版本	Draft v1.0 2026 年 5 月
草稿日期	2026 年 5 月 14 日 (星期四) 作者：凡
文档状态	工作草稿 (Working Draft) —— 仅供内部审阅，未定稿

第一部分

引言与研究背景 (Introduction & Background)

1.1 研究动机

大型语言模型 (LLM) 的普及——尤其是 ChatGPT、Claude、Gemini、Llama 等工具的广泛应用——引发了针对 AI 生成文本真实性的深层危机。2023 年以来，学术论文、新闻报道、营销

文案乃至法律文书中的 AI 生成比例急剧攀升，由此催生了对可靠 *AI-generated text detection* (AI 文本检测) 工具的迫切需求。

本综述正是在这一背景下展开：系统梳理针对 AI 文本检测的主要对抗手段——尤其是 *AI Humanizers* 与 *Adversarial Paraphrasing*——及其对现有检测体系造成的冲击，并评估当前防御机制的有效性与局限性。

1.2 核心对立关系：猫鼠游戏框架

AI 文本生成器与 AI 文本检测器之间构成了一种典型的军备竞赛 (*arms race*) 格局，学界将其形象地称为"猫鼠游戏" (*cat-and-mouse game*)：每当检测器性能提升，攻击者即通过改写 (paraphrasing)、风格迁移 (style transfer) 或字符级篡改 (character-level manipulation) 加以规避；而新型规避手段的出现，又倒逼检测器进一步迭代。此螺旋式博弈的非对称性——攻击成本极低、防御成本高昂——是理解该领域技术演化逻辑的核心框架。

1.3 AI Humanizer 的定义与兴起

AI Humanizer 泛指一类旨在修改 AI 生成文本、使其规避检测器识别并呈现出"人类写作风格"特征的工具或方法。其演进路径大致如下：

1. **早期 (2022 年前)**：简单同义词替换与句式变换，效果有限；
2. **2022—2023 年**：基于神经网络的改写模型 (如 DIPPER、PEGASUS) 出现，语义保真度显著提升；
3. **2024—2026 年**：商业化 AI Humanizer 服务 (StealthGPT、Humanize AI Pro 等) 兴起，同时字符级隐写攻击 (homoglyph attack) 成为新型威胁向量。

1.4 研究范围界定

1.4.1 涵盖内容

- AI Humanizer 方法分类 (规则驱动型、神经网络型、提示工程型、混合管道型、字符级攻击型)
- Adversarial Paraphrasing 技术及其对检测器的实验性冲击
- AI 文本检测器的脆弱性分析 (改写攻击、OOD 泛化失败、公平性偏差)

- 防御策略：水印鲁棒性、检索增强防御、Unicode 归一化等
- 伦理、法律与政策维度（学术诚信政策、立法动态）

1.4.2 排除内容

- 图像 / 音频 / 视频生成内容的检测（多模态检测）
- 多模态 AI 内容鉴伪（deepfake 视频检测等）
- 传统版权抄袭检测（非 AI 生成角度）
- 以模型训练数据为对象的成员推断攻击（membership inference）

1.5 综述方法论（PRISMA 框架简述）

1.5.1 检索数据库

- arXiv（cs.CL, cs.CR, cs.LG） · ACL Anthology · IEEE Xplore
- Semantic Scholar · Google Scholar · ACM Digital Library

1.5.2 关键词策略

主检索式（Boolean 组合）：

(AI humanizer OR text humanization OR adversarial paraphrasing OR AI-generated text evasion) AND (AI text detection OR LLM detection OR watermarking OR GPTZero OR DetectGPT)

1.5.3 纳入/排除标准

维度	纳入标准	排除标准
时间跨度	2022 年 1 月—2026 年 5 月	2022 年前发表（除奠基性工作外）
语言	英文、中文	其他语言（无英文摘要者）
发表形式	同行评审论文、顶会（ACL/EMNLP/NeurIPS/ICML）、arXiv 预印本（被引≥10 次）	博客、非学术报告、未公开数据支撑的商业白皮书
研究主题	直接涉及 AI 文本检测或 AI	仅概念性讨论而无实验验证的

维度	纳入标准	排除标准
	humanization 的实验性研究	工作

1.5.4 时间跨度

2022 年 1 月—2026 年 5 月（重点覆盖 ChatGPT 发布后至今）。

1.6 综述结构导览

- 第一部分：引言与研究背景
 - 研究动机 → 核心对立关系 → 研究范围 → 方法论
- 第二部分：AI 文本检测方法综述
 - 水印技术 → 统计方法 → 监督学习方法 → 检索增强防御 → 横向对比
- 第三部分：AI Humanizer 与对抗性改写方法分类
 - 规则驱动 → 神经改写 → 提示工程 → 字符级攻击 → 混合管道 → 横向对比
- 第四部分：检测器脆弱性分析
 - 改写攻击证据 → OOD 泛化失败 → 公平性偏差 → 水印脆弱性
- 第五部分：防御策略与反制措施
- 第六部分：实验数据与基准数据集
- 第七部分：理论框架与跨学科视角
- 第八部分：研究空白与未来研究方向
- 第九部分：结论 & 参考文献框架

AI 文本检测方法综述 (AI Text Detection Methods)

2.1 检测方法分类框架

表 2-1 AI 文本检测方法总览 (综合文献归纳)

方法类别	代表工具 / 论文	核心原理	主要优势	主要局限
水印技术 Watermarking	Kirchenbauer et al. 2023 ; Aaronson 方案 ; Google 2024	在生成阶段向 token 分布注入统计偏置信号	零误报可控 ; 可设计为对 API 用户不可见	改写攻击可破坏水印 ; 开源模型无法强制部署
统计 / 零样本方法 Statistical / Zero-shot	DetectGPT (Mitchell 2023) ; Fast-DetectGPT ; PPL 阈值	利用 LLM 对自身输出的困惑度/概率曲率特征	无需训练数据 ; 模型无关	改写后统计分布改变 ; 短文本效果差
监督学习分类器 Supervised Classifiers	RoBERTa-based ; GPTZero ; Turnitin AI ; Originality.ai	在标注数据集上微调二分类器	精度高 (内部基准) ; 部署便捷	泛化差 ; 对新模型输出退化 ; 数据集依赖
检索增强防御 Retrieval-based	Krishna et al. NeurIPS 2023 (DIPPER 论文)	语义相似度检索已知 AI 生成数据库	对改写攻击鲁棒 ; 误报率极低 (~1%)	需维护大规模生成数据库 ; 不适用于开放模型
多模型集成 Ensemble	多工具联合投票 ; Binoculars	融合多个检测器的置信度输出	单一检测器失效时提供冗余保障	复杂度高 ; 推断速度慢 ; 仍受改写影响

2.2 水印技术 (Watermarking)

2.2.1 Green-Red Token List 水印

Kirchenbauer et al. (2023) 提出的核心方案 : 在生成时将词表随机划分为"绿色"与"红色" token 集合 , 并对绿色 token 的 logits 施加固定偏置 (*logit addition*) , 使 AI 输出文本中绿

色 token 比例显著高于随机基线。检测阶段通过统计显著性检验 (z-score) 识别水印信号。

Aaronson 方案 (OpenAI) 采用类似思路的密码学安全版本。

2.2.2 Gumbel 水印与 Logits-Addition 水印变体

Gumbel 水印方案通过操纵采样过程的随机种子实现更高的统计功效；Logits-Addition 变体则允许调控水印强度，在文本质量与可检测性之间寻求平衡。

2.2.3 鲁棒性评估：抗改写攻击能力

现有实验表明，token 级水印对段落级改写（如 DIPPER 攻击）脆弱：改写后 token 分布被打乱，绿色 token 比例恢复至随机水平，水印失效。这是当前水印技术最核心的未解难题。

2.2.4 Nature 2024 可扩展水印方案 (Google)

Google 研究团队于 2024 年在 *Nature* 发表了语义级水印方案，将水印注入语义表示层而非 token 层，理论上对词法改写具备更强鲁棒性。该方案已在 Gemini 系列模型中部署，为大规模商业水印应用提供了重要参考。

2.3 统计方法 (Statistical / Zero-shot Methods)

2.3.1 Perplexity (困惑度) 阈值检测

利用 AI 生成文本困惑度 (PPL) 普遍低于人类写作这一统计规律。设定 PPL 阈值，低于阈值则判定为 AI 生成。该方法简单直接，但对精心改写或多样化采样参数（高温度）的输出效果有限。

2.3.2 Burstiness (句长方差) 分析

AI 生成文本句长往往较为均匀（低 burstiness），而人类写作呈现更强的长短句交替特征（高 burstiness）。作为辅助特征使用时有一定区分度，但单独使用准确率不足。

2.3.3 DetectGPT (Mitchell et al., ICML 2023)

核心思想：对候选文本施加随机扰动，观察其对数概率曲率 (*log-probability curvature*) —— AI 生成文本通常处于对数概率的局部极大值，因而扰动后概率下降；人类文本则无此规律。原始 AUROC 从 PPL 方法的 0.81 提升至 0.95，但面对改写攻击时性能骤降（见第四部分）。

2.3.4 Fast-DetectGPT 及后续改进

通过条件概率估计取代逐样本扰动，将检测速度提升约 340 倍，同时维持与 DetectGPT 相当的准确率。后续工作（如 Binoculars）进一步引入双模型对比机制，提升了对混合文本的检测能力。

2.4 监督学习方法 (Supervised Classifiers)

2.4.1 基于 RoBERTa/BERT 的二分类器

在 AI-人类配对语料上微调 RoBERTa/BERT 等预训练模型，实现端到端二分类。训练域内表现优异，但跨模型（如 GPT-4 → Claude）与跨领域泛化能力较弱。

2.4.2 主要商业工具对比

- **GPTZero**：多维度特征融合（PPL + burstiness + 监督分类），提供段落级细粒度报告；
- **Turnitin AI**：集成于成熟学术诚信平台，但误差范围约 $\pm 15\%$ ；
- **Originality.ai**：面向内容创作市场，提供 API 接口；
- **Copyleaks / Winston AI**：主打多语言支持，商业宣称准确率（99%+）与独立测评存在系统性差距。

2.4.3 多模型联合检测 (Ensemble Approaches)

对多个检测器输出进行投票或加权融合，可在单一检测器失效时提供一定保障。但若所有成员检测器对同一改写攻击均脆弱，集成方法亦无法从根本上解决问题。

2.5 检索增强防御 (Retrieval-based Defense)

Krishna et al. (NeurIPS 2023) 在 DIPPER 论文中同时提出了对应防御机制：由语言模型 API 提供商维护一个包含约 1500 万条已生成文本的数据库，对任意待测文本执行语义相似度检索。若检索到超过相似度阈值的匹配项，则判定为 AI 生成文本。实验结果：在多种设置下检出率达 80%-97%，同时人类文本误报率仅约 1%。

- 实施约束

该方案需要 API 提供商的主动配合与持续数据库维护，对开源模型（如 Llama）不可直接适用，且存在规模化成本与用户隐私方面的争议。

2.6 检测器性能横向对比

表 2-2 主要检测器性能对比（数据来源：GPTZero 2026 内部基准、isGPT 2025 对比实验、PeerJ 2025）

检测器	FPR (误报率)	Recall (召回率)	Accuracy (准确率)	对改写文本鲁棒性	数据来源
GPTZero (4.3b)	0.08%	99.60%	99.76%	▼ 骤降 (humanized 文本检出率 <8%)	GPTZero 2026 内部基准
Originality.ai (lite-102)	1.88%	93.05%	95.59%	▼ 显著下降	isGPT 2025
Turnitin AI	~15% (±)	~80% (报告值)	~85% (报告值)	▼ 对改写高度脆弱	PeerJ 2025；独立测评
Copyleaks	未公开	宣称 99%+	独立测评 ~66%	▼ 脆弱	Scribbr 独立测评
DetectGPT	固定 1% (FPR)	70.3% (攻击前)	—	▼▼ 极脆弱 (DIPPER 攻击后降至 4.6%)	Krishna et al. NeurIPS 2023
检索增强防御	~1%	80%-97%	—	▲ 对改写鲁棒	Krishna et al. NeurIPS 2023

⚠ 关键注意事项

上表中高准确率数据（如 GPTZero 99.76%）均来自厂商内部基准测试，未经同行评审独立验证。所有商业工具在面对经过 humanization 处理的文本时，检出率均骤降至 8% 以下，揭示了当前检测技术的系统性脆弱性。

AI Humanizer 与对抗性改写方法分类 (Taxonomy of AI Humanizers & Adversarial Paraphrasing)

3.1 分类框架总览

- **A. 规则驱动型 (Rule-based)**
 - 模式替换 · 句法变换 · 人类痕迹注入
- **B. 神经网络改写型 (Neural Paraphrase Models)**
 - DIPPER (11B) · PEGASUS · T5-XXL · BART
- **C. 回译型 (Back-translation)**
 - 多语言中转：EN → FR/ZH/DE → EN
- **D. 提示工程型 (Prompt-based / Instruction-tuned LLM)**
 - 直接指令 · 角色扮演改写 · 迭代检测-改写循环
- **E. 混合管道型 (Hybrid Pipelines)**
 - 神经改写 + 规则微调 + 检测分数反馈循环
- **F. 字符级攻击型 (Character-level / Steganographic Attacks)**
 - 同形字符替换 (Homoglyph) · 零宽字符注入

3.2 规则驱动型方法 (Rule-based Humanizers)

3.2.1 模式替换

系统性识别并替换 AI 写作的高频标志性词汇，如 `delve into`、`it's worth noting`、`in conclusion`、`furthermore` 等。这类词汇在人类非正式写作中出现频率较低，但在 LLM 输出中高度集中，形成可被检测器利用的统计特征。

3.2.2 句法变换

包括：被动语态↔主动语态转换、复合句拆分为短句、简单句合并为复杂句、句子头部成分调换等。目标在于打破 AI 生成文本的句式均匀性（低 burstiness 特征）。

3.2.3 注入"人类痕迹"

刻意引入口语化表达、收缩形式（*contractions*：don't、it's、I've）、轻微的标点不规范、个人化语气词等，以模拟人类非正式写作的语用特征。

3.2.4 局限性与代表工具

规则驱动型方法无法从根本上改变 AI 生成文本的深层统计分布（如 token 概率曲率），对依赖深层语言模型特征的神经网络检测器（如 DetectGPT）效果有限。代表工具 Cereby Humanizer 采用"双阶段规则+神经管道"设计，实验报告检测分数从 68% 降至 51%（下降 17 个百分点），但仍未能完全规避神经检测器。

3.3 神经网络改写型 (Neural Paraphrase Models)

3.3.1 DIPPER (Krishna et al., NeurIPS 2023)

DIPPER (*Diverse Paraphrase Generation*) 是目前学界最具代表性的对抗性改写模型，参数量 11B。其核心特性：

- **段落级上下文感知**：改写时以周围段落为条件输入，保持篇章连贯性；
- **可控词汇多样性**：通过超参数调控词汇替换比例（lexical diversity knob）；
- **内容重排序**：支持句子顺序调整（content reordering）以进一步混淆统计特征。

实验结果：DIPPER 将 DetectGPT 的检测准确率从 70.3% 降至 4.6%（固定 FPR=1%），同时成功绕过 GPTZero、OpenAI 文本分类器及 token-level 水印，且语义保真度几乎不受损（基于 BERTScore 验证）。

3.3.2 PEGASUS、T5-XXL 及 BART 系列

PEGASUS（Google）专为摘要与改写设计，在学术摘要改写中表现良好；T5-XXL 通过 span corruption 预训练具备强大的生成多样性；BART 的 encoder-decoder 架构在 seq2seq 改写任务中被广泛采用。三者与 DIPPER 相比，缺乏段落级上下文感知能力，攻击效果略逊于 DIPPER。

3.3.3 优势总结

神经改写型方法的核心优势在于：语义保真度高（BLEU/BERTScore 损失小）、规模化改写能力强、对统计检测器破坏效果显著——这是规则驱动型方法难以企及的。

3.4 提示工程型方法（Prompt-based Methods）

3.4.1 直接指令法

向 LLM 提交简单指令，如：“请用更自然、人性化的语气重写以下内容，避免使用 AI 写作的典型表达。”操作成本极低，但效果受限于模型对“人类语气”的理解深度，且不同模型表现差异显著。

3.4.2 角色扮演改写

要求 LLM 模拟特定风格的人类作者（如“用一位有 20 年经验的新闻记者的口吻改写”），有时可显著提升输出的个性化程度。但此类方法依赖提示工程技巧，可重复性较差。

3.4.3 迭代式改写（检测-改写循环）

自动化多轮流程：将文本提交检测器 → 获取 AI 概率分数 → 若高于阈值则重新改写 → 循环至分数低于目标阈值。StealthGPT 等商业工具采用此策略（多引擎切换 + 迭代优化），号称可将所有主流检测器规避。

3.4.4 商业工具对比

表 3-1 主要商业 AI Humanizer 工具对比

工具名称	核心方法	目标检测器	宣称效果	独立验证情况
StealthGPT	迭代式改写 + 多引擎切换	GPTZero、Turnitin、Originality	规避率 >90%	缺乏同行评审验证
Humanize AI Pro	提示工程 + 神经改写	通用检测器	规避率 85%+	内部测试，无独立数据
Overchat AI	规则驱动 + 指令微调	GPTZero、Turnitin	规避率 ~80%	用户自报数据
StudyAgent	多步骤提示工程	学术诚信平台	宣称通过 Turnitin	无学术论文验证

3.5 字符级与隐写攻击 (Character-level & Steganographic Attacks)

3.5.1 同形字符替换 (Homoglyph Attack) ——SilverSpeak

Creo & Pudasaini (2024, COLING 2025 收录) 提出 SilverSpeak : 将 AI 生成文本中的部分拉丁字符系统性地替换为视觉上完全相同但 Unicode 码位不同的字符 (如拉丁字母 **A** (U+0041) → 西里尔字母 **А** (U+0410))。人类读者无法察觉差异, 但检测器的 tokenizer 将处理完全不同的 token 序列。

实验结果 :

- Matthews Correlation Coefficient (MCC) 从 0.64 骤降至 -0.01 (接近随机猜测) ;
- ArguGPT、Binoculars、token 水印等 7 个主流检测器全部失效 ;
- 攻击成本极低 (无需 GPU, 纯字符替换) , 是当前最具威胁性的低成本攻击之一。

3.5.2 零宽字符注入 (Zero-width Characters)

在文本中插入零宽不连字 (ZWNJ)、零宽连字 (ZWJ)、零宽空格 (ZWSP) 等不可见字符, 破坏检测器的 token 分割逻辑, 同时对人类读者完全透明。

3.5.3 防御讨论

对字符级攻击最直接的防御手段是在检测前执行 Unicode 归一化 (*Unicode Normalization* , NFKC 标准) , 将所有同形字符统一映射至标准码位 ; 同时可引入字符白名单过滤, 拒绝非目标语言字符集的输入。

3.6 混合管道型方法 (Hybrid Pipelines)

混合管道将神经改写与规则微调结合为两阶段流程：第一阶段使用神经模型进行语义层面的深度改写，第二阶段应用规则系统补充词法特征调整（收缩形式、句长变化）；并嵌入检测分数反馈循环，自动迭代至目标分数以下。

部分工作探索了 *Out-of-Distribution (OOD) 迁移攻击*：用针对 GPT-3.5 训练的攻击方法迁移至 GPT-4 或 Claude 输出，验证跨模型攻击迁移性。

3.7 AI Humanizer 方法横向对比总表

表 3-2 各类 AI Humanizer 方法多维度对比

方法类型	代表方法	改写粒度	语义保真度	对统计检测器效果	对神经检测器效果	计算成本
规则驱动型	Cereby Humanizer	词 / 句	高	中等	低	极低
神经改写型	DIPPER (11B)	段落	高	极高	高	高 (需 40GB+ GPU)
回译型	多语言 NMT 中转	句 / 段	中等	中等	中等	低—中
提示工程型	StealthGPT；直接指令	段落 / 全文	中—高	高	中等	低 (API 调用费用)
字符级攻击型	SilverSpeak；ZWNJ 注入	字符	完美 (视觉)	极高	极高	极低
混合管道型	神经改写 + 规则 + 反馈循环	全文	高	极高	高	中—高

检测器脆弱性分析 (Detector Vulnerability Analysis)

4.1 脆弱性分类框架

- A. 改写攻击脆弱性 (Paraphrase Attack Vulnerability)** : 语义保留的文本改写破坏统计检测特征 ;
- B. 分布外泛化失败 (Out-of-Distribution Failure)** : 检测器在训练域外 (不同模型、不同领域) 性能退化 ;
- C. 字符级攻击脆弱性 (Character-level Attack Vulnerability)** : Unicode 攻击绕过 tokenizer 层 ;
- D. AI-Human 混合文本检测困难 (Hybrid Text)** : 人机协作写作的边界模糊 ;
- E. 对抗性提示诱导 (Adversarial Prompt Elicitation)** : 通过精心设计的提示使 LLM 输出更难被检测的文本。

4.2 改写攻击实验证据汇总

★ 关键发现 (Key Finding) —— DIPPER 攻击的毁灭性影响

Krishna et al. (NeurIPS 2023) 证明, DIPPER 在 FPR=1% 固定约束下, 将 DetectGPT 的检测准确率从

70.3%

骤降至

4.6%

, 降幅高达

65.7 个百分点

。同一模型同时成功绕过 GPTZero、OpenAI 官方文本分类器及 token 水印方案，且改写后文本在 BERTScore 语义相似度指标上几乎未见明显下降。这一结果在学界被广泛引用，标志着"改写即规避"成为当前 AI 文本检测领域最核心的未解问题。

表 4-1 改写攻击实验结果汇总

原始检测器	攻击方法	攻击前准确率	攻击后准确率	来源论文
DetectGPT	DIPPER (段落级改写)	70.3%	4.6% (FPR=1%固定)	Krishna et al., NeurIPS 2023
GPTZero	DIPPER	显著有效 (基线)	显著下降 (具体数值未完全公开)	Krishna et al., NeurIPS 2023
OpenAI 官方文本分类器	DIPPER	有效 (基线)	被完全绕过	Krishna et al., NeurIPS 2023
Token 水印 (KGW)	DIPPER	水印有效	水印信号被破坏，检测失效	Krishna et al., NeurIPS 2023
7 个主流检测器 (含 ArguGPT、Binoculars、水印)	Homoglyph 攻击 (SilverSpeak)	MCC 均值 0.64	MCC 均值 - 0.01 (全部失效)	Creo & Pudasaini, COLING 2025
所有主流商业工具	AI Humanizer 处理后的文本	正常检出率 (基线)	<8% (2026 Leaderboard 数据)	GPTZero 2026 Benchmark

4.3 分布外泛化失败 (OOD Failure)

4.3.1 跨 LLM 泛化问题

在 GPT-3.5 输出上训练的分类器对 Claude、Gemini 或 Llama 的输出泛化能力显著下降。不同 LLM 的 token 概率分布存在模型特定偏置，导致检测器实质上学习的是"哪个模型的风格"而非"是否由 AI 生成"这一本质问题。

4.3.2 跨领域性能差异

同一检测器在不同文本领域的性能差异显著：学术写作场景（正式、低 burstiness）准确率约 82.5%-90%，而社交媒体与日常写作场景（口语化、高 burstiness）准确率骤降至约 57.5%-67.5%，接近随机猜测水平。

4.4 公平性与偏差问题 (Fairness & Bias)

4.4.1 非母语英语写作者的高误报率

Stanford 研究团队 (Liang et al., 2023，发表于 *Patterns*) 发现：对非母语英语写作者 (English Language Learner, ELL) 的文章，7 个主流 AI 检测器的平均误报率高达 **61.3%**——即超过 60% 的真实人类写作被误判为 AI 生成。这一比例在母语写作者中仅约 20%。

4.4.2 误报率差异量化

非母语英语写作者被误判为 AI 的概率最高可达母语写作者的 **3 倍**。这一偏差的根源在于：ELL 写作倾向于使用较为规范、简洁的句式，与 LLM 输出的表面统计特征高度重叠。

4.4.3 正式风格与学术写作的误判问题

Turnitin AI 对高度正式的学术写作存在系统性偏差（误差范围约 $\pm 15\%$ ），有据可查的案例显示部分历史文献、哲学论文片段被标记为 AI 生成。

4.4.4 高校政策回应

鉴于上述可靠性问题，多所大学已明确限制或禁止将 AI 检测工具用于学术诚信裁决，包括：Vanderbilt 大学、Curtin 大学（澳大利亚）及新西兰多所高校。这些机构转向以过程证据为核心的评估体系。

4.4.5 准确性-公平性权衡理论框架

当前 AI 文本检测领域存在一个内在张力：提升检测灵敏度 (Recall) 不可避免地导致非母语写作者误报率上升 (FPR 增加)，反之亦然。正式提出并量化这一"准确性-公平性权衡" (*Accuracy-Fairness Trade-off*) 框架，是未来研究的重要理论任务。

4.5 商业工具宣称 vs. 独立测评的系统性差距

表 4-2 商业宣称准确率 vs. 独立测评对比

工具	厂商宣称准确率	独立测评准确率	测评来源
Copyleaks	99%+	~66%	Scribbr 独立测评
Winston AI	99.6%	~72% (独立语料)	PeerJ 2025
Originality.ai	~95% (内部基准)	~80% (新模型输出)	isGPT 2025

这一系统性高估的核心原因在于：厂商基准测试往往使用与训练集同分布的数据，而非真实世界中多样化的 AI 生成场景与 humanization 处理后的文本。

4.6 针对水印方案的攻击

token 分布水印（Green-Red List 方案）的核心脆弱性在于：任何语义保留的改写都可以随机打乱 token 选择，从而破坏水印信号。若攻击者知晓水印方案（白盒攻击），还可以主动生成使绿色 token 比例回归随机水平的改写文本。语义保留的改写如何在不破坏内容意义的前提下绕过 Green-Red List 检测，目前仍是开放性研究问题。

第五部分

防御策略与反制措施 (Defense Strategies & Countermeasures)

5.1 防御框架总览

- **被动防御**：提升检测器本身的鲁棒性——使其在受到改写攻击时性能退化更少；
- **主动防御**：在生成侧植入可溯源信号（水印、数字签名）——使规避行为留下可追踪痕迹。

5.2 提升检测器鲁棒性

5.2.1 文本扰动鲁棒性增强训练

在训练数据中加入各类改写/扰动后的 AI 文本（数据增强），使检测器学习到对表层词法变化具有不变性的深层特征。但此方案存在"打地鼠"困境：需要预见并覆盖所有未来攻击类型。

5.2.2 集成检测 (Ensemble Detection)

集成多个基于不同原理的检测器（统计方法 + 神经分类器 + 检索增强），要求攻击方同时规避所有成员检测器，显著提高攻击难度。但集成系统的计算成本与推断延迟是实际部署中的主要障碍。

5.2.3 OOD 鲁棒性：跨域训练数据扩充

纳入多 LLM（GPT、Claude、Gemini、Llama、Mistral）和多领域（学术、新闻、社交媒体、法律、医学）的训练语料，以缓解分布外泛化失败问题。目前已有若干多源数据集（如 M4 数据集）支持此方向。

5.2.4 AI-Human 混合文本检测专项训练

构建覆盖"纯 AI 生成—部分 AI 生成—轻度 AI 辅助—纯人类写作"连续谱系的标注数据集，训练能够输出连续置信度分数（而非二值标签）的细粒度检测器。

5.3 溯源与水印防御

5.3.1 检索增强防御 (Krishna et al., NeurIPS 2023)

详见第 2.5 节。15M 数据库检索方案在多种设置下检出率达 80%-97%，是目前针对改写攻击最鲁棒的防御方案之一。其根本优势在于：将检测问题从"识别统计特征"转变为"数据库查询匹配"，后者对改写具有天然的不变性（若改写后语义相似，则检索仍可命中）。

5.3.2 内容溯源 (Content Provenance)

C2PA (*Coalition for Content Provenance and Authenticity*) 标准：在内容创作时嵌入数字签名与元数据，记录创作工具、时间与来源，供下游验证。目前已获 Adobe、Microsoft、Google 等主要厂商支持，但对事后生成的内容无法追溯。

5.3.3 鲁棒语义水印

在语义表示层（而非 token 层）注入水印信号，理论上对词法改写更鲁棒。Google 2024 年 *Nature* 方案是当前最具代表性的工作，但其在强语义改写（意译、段落重构）下的鲁棒性仍有待评估。

5.4 非技术防御策略

5.4.1 过程导向评估 (Process-oriented Assessment)

要求学生提交写作过程证据（草稿历史、修订记录、Google Docs 版本历史），并结合口头答辩 (*viva voce*) 评估，以验证作者身份。这是目前最被教育机构采纳的非技术防御手段。

5.4.2 双阶段作业设计

第一阶段：课堂内封闭式写作（限时、无网络）；第二阶段：提交完整论文。通过两阶段比对识别显著不一致的写作风格。

5.4.3 AI 检测多元证据政策

将 AI 检测工具输出作为“参考信号”而非“终审证据”，结合教师人工判断、学生写作历史档案、课程内容相关性等多元证据综合评估。明确禁止仅凭单一检测分数作出学术处分决定。

5.5 字符级攻击防御

- **Unicode NFKC 归一化**：在文本进入检测器前执行 NFKC 标准化，将所有同形变体字符映射回标准码位（如所有西里尔/希腊同形字符 → 对应拉丁字符）；
- **字符白名单过滤**：仅允许目标语言标准字符集（ASCII + 扩展拉丁字符），拒绝或替换白名单外的 Unicode 字符；
- **异常字符检测**：统计文本中非标准字符比例，超过阈值则标记为可疑并触发人工审查。

第六部分

实验数据与基准数据集综述 (Experimental Data & Benchmark Datasets)

6.1 主要基准数据集一览

表 6-1 AI 文本检测领域主要基准数据集

数据集名称	来源 / 论文	文本类型	规模 (约)	标注方式	主要用途
HC3	Guo et al., 2023	问答对 (中/英)	24K 问题 / 58K 答案	人类 vs. ChatGPT 自动配对	检测器训练与基准测试
TuringBench	Uchendu et al., 2021	新闻文章	168K 样本, 19 种生成器	多 LLM 来源标注	多模型区分测试
M4 Dataset	Wang et al., 2023 (EACL 2024)	多领域多语言	122K 样本, 6 种语言	多 LLM 多领域标注	多语言/跨领域鲁棒性评估
RAID Benchmark	Dugan et al., 2024 (ACL 2024)	多领域英文	500K+ 样本	11 种生成器 × 多种改写攻击	检测器鲁棒性全面评测
DIPPER 改写数据集	Krishna et al., NeurIPS 2023	学术/新闻文章段落	~15M 条生成样本 (防御库)	GPT-3.5 生成 + DIPPER 改写	改写攻击与检索防御评估
GPTZero Benchmark 2026	GPTZero 内部 (未公开)	多领域英文	未公开	人工+自动标注	商业工具性能声明依据

6.2 评测指标标准化

表 6-2 主要评测指标适用场景分析

指标	定义	适用场景	局限性
AUROC	ROC 曲线下面积	评估检测器在不同决策阈值下的性能	类别不平衡时可能高估性能

指标	定义	适用场景	局限性
		策阈值下的综合鉴别能力	估性能
Accuracy	正确分类比例	平衡数据集上的整体性能概览	类别不平衡时误导性强
FPR（假阳性率）	人类文本被误判为 AI 的比例	公平性评估的核心指标；关注误伤人类作者场景	需结合 Recall 联合解读
FNR（假阴性率）	AI 文本被漏检的比例	评估规避攻击后的检测遗漏率	与 Recall 互补（ $FNR = 1 - Recall$ ）
MCC（Matthews 相关系数）	综合考虑 TP/TN/FP/FN 的平衡指标	类别不平衡场景；SilverSpeak 等攻击评估	计算复杂，直觉理解难度较高

6.3 基准测试方法论问题

- **数据泄漏风险**：商业检测器训练集与公开评测集之间的重叠难以排查，可能导致性能虚高；
- **短文本检测局限**：大多数检测器要求最小输入长度（通常 50 词/250 字符），对摘要、标题等短文本无效；
- **跨语言测试的系统性缺失**：绝大多数基准仅覆盖英语，非英语 AI 文本检测几乎是空白；
- **时效性问题**：以旧模型（如 GPT-3.5）输出为测试目标的基准，对 GPT-4o、Claude 3.7 等新模型参考价值有限。

6.4 关键实验结果综合对比

表 6-3 核心攻防实验结果综合对比（跨论文汇总）

研究场景	攻击方法	被测检测器	攻击前指标	攻击后指标	来源
段落级神经改写攻击	DIPPER (11B)	DetectGPT	Acc. 70.3% @ FPR=1%	Acc. 4.6% @ FPR=1%	Krishna et al., NeurIPS 2023
字符级同形替换攻击	SilverSpeak Homoglyph	7 个检测器均值	MCC 0.64	MCC -0.01	Creo & Pudasaini, COLING

研究场景	攻击方法	被测检测器	攻击前指标	攻击后指标	来源
					2025
检索防御对改写攻击的鲁棒性	DIPPER 改写	检索增强防御	—	检出率 80–97%，FPR ~1%	Krishna et al., NeurIPS 2023
非母语写作者误报率	无攻击（人类写作）	7 个商业工具	母语作者 FPR ~20%	ELL 作者 FPR 61.3%	Liang et al., Patterns 2023
跨域性能退化	无攻击（域变化）	监督分类器	学术域 Acc. 82.5–90%	社交媒体域 Acc. 57.5–67.5%	PeerJ 2025

第七部分

理论框架与跨学科视角（Theoretical Frameworks & Interdisciplinary Perspectives）

7.1 军备竞赛框架（Arms Race Framework）

生成器与检测器的对抗博弈符合博弈论中的经典"捉迷藏"（*hide-and-seek*）框架：

- **攻防非对称性**：开发一种新型改写攻击（如提示工程型）的成本（数小时）远低于训练一个鲁棒检测器的成本（大规模数据标注 + 计算资源），攻击方处于天然优势；
- **先动优势**：检测器必须在观察到新型攻击后才能针对性训练，而攻击者可主动探索最新检测器的盲区；
- **理论上限的存在性**：部分研究者认为，对于公开可用的 LLM，在理论上不存在完全可靠的 AI 文本检测器（Sadasivan et al., 2023），指出在高质量 LLM 输出场景下，人类文本与 AI 文本的统计距离趋近于零。

7.2 信息论视角

- **水印信道容量限制**：水印信号的可嵌入容量 (*payload capacity*) 受限于文本的信息熵，强水印会影响文本质量，两者存在根本性权衡；
- **语义保真度与可检测性的信息论权衡**：改写攻击本质上是在"保留语义信息"与"破坏检测信号"之间寻求 Pareto 最优解，可形式化为约束优化问题；
- **不可检测性下界**：理论工作表明，若 LLM 输出分布与人类写作分布之间的 KL 散度趋近于零，则任何检测器的误差率均有下界。

7.3 法律与伦理视角

7.3.1 学术诚信政策演变

从"禁止使用 AI"到"披露式使用"再到"过程导向评估"，各高校政策在 2023-2026 年间经历了快速演变，尚未形成国际统一标准。

7.3.2 AI 内容标注立法动态

- **欧盟 AI 法案 (EU AI Act)**：要求 AI 生成内容（尤其是合成媒体）进行明确标注，对高风险 AI 系统实施强制透明度要求；
- **美国行政令 EO 14110 (2023)**：要求联邦机构制定 AI 内容真实性标准，推动 C2PA 等内容溯源技术的政府采购；
- **中国《生成式人工智能服务管理暂行办法》(2023)**：要求对 AI 生成内容进行显著标识。

7.3.3 监控与隐私的张力

大规模 AI 文本检测系统的部署（尤其是检索增强防御需要维护用户生成历史数据库）引发了对数据隐私与监控的伦理关切，需在学术诚信保障与个人隐私权之间寻求政策平衡。

7.4 社会影响视角

7.4.1 对教育公平性的影响

当前 AI 检测工具对非母语写作者的系统性偏差，实质上加剧了教育机会不平等：语言劣势学生在同等 AI 使用程度下面临更高的被误判风险，构成隐性的教育歧视。

7.4.2 新闻与信息生态系统

AI 生成新闻内容的泛滥 (*content farming*) 与 Humanizer 工具的结合，使虚假信息的规模化生产与传播成本趋近于零，对公共信息生态系统构成深层威胁。

第八部分

研究空白与未来研究方向 (Research Gaps & Future Directions)

8.1 当前研究空白识别

 **Research Gap Alert** ——研究空白预警

以下研究空白经系统性文献检索确认，截至 2026 年 5 月均未有充分解决。其中标注为“高影响”的方向代表着该领域内最紧迫的科学与政策需求，建议研究者优先关注。

表 8-1 AI 文本检测领域主要研究空白识别清单

研究空白	影响程度	已有初步工作	建议研究路径
可靠大规模 AI 内容溯源技术	高	C2PA 标准；Google SynthID	密码学嵌入 + 语义水印的跨层融合方案

研究空白	影响程度	已有初步工作	建议研究路径
多语言检测鲁棒性 (非英语)	高	M4 数据集（6 语言）；初步跨语言实验	多语言预训练检测器 + 跨语言迁移学习
句子/段落级细粒度 AI-Human 混合溯源	高	部分商业工具有段落级输出	序列标注 + span-level 检测框架
公平性感知检测器 (Fairness-aware)	高	Liang et al. 2023 偏差分析	约束优化：在 ELL FPR 约束下最大化 Recall
开源 LLM 的水印强制部署机制	高	无（现有水印均依赖 API 提供商）	模型权重层面的水印嵌入 + 防篡改机制
对抗训练对检测器的鲁棒性提升	中	扰动增强训练初步工作	GAN-style 检测器-攻击者联合训练框架
AI-Human 混合写作的法律定义与证据标准	中	各国立法初探；高校政策文件	跨学科：计算机科学 + 法学 + 教育学政策研究
实时检测（低延迟部署）	中	Fast-DetectGPT（~340 × 加速）	轻量化检测架构；边缘计算部署研究
字符级攻击的标准化防御基准	低—中	Unicode NFKC 归一化（临时方案）	建立标准化预处理规范 + 攻击鲁棒性评测套件

8.2 高优先级未来研究方向

8.2.1 可靠 AI 内容溯源

目前学界普遍认为，在大规模开放模型场景下，完全可靠的 AI 内容溯源在技术上尚不可行。未来研究需要在密码学强度水印与语义水印之间寻求融合路径，并解决开源模型无法强制部署水印的根本性障碍。

8.2.2 多语言检测鲁棒性

现有研究对非英语（尤其是低资源语言）AI 文本检测几乎空白。中文、阿拉伯语、印地语等主要语言的 AI 文本特征及对应检测方法亟需系统性研究。M4 数据集为此提供了初步基础，但规模与覆盖度均不足。

8.2.3 AI-Human 混合写作的细粒度检测

未来的写作模式将越来越多地表现为"人机协作" (human-AI co-writing)，而非简单的"全 AI 生成"。句子级或段落级的 AI 内容溯源 (*span-level attribution*) 是下一代检测技术的核心挑战。

8.2.4 对抗训练与鲁棒性增强新范式

探索 GAN-style 的检测器-改写器联合训练框架：改写器负责生成最难检测的 humanized 文本，检测器在此对抗压力下持续迭代提升鲁棒性，最终达到动态纳什均衡。

8.2.5 公平性感知检测器设计

在检测器训练目标函数中显式纳入公平性约束（如：要求不同语言背景写作者的 FPR 差异不超过既定阈值），在准确性与公平性之间寻求帕累托最优点。

8.2.6 改革评估体系：以过程为中心的学术诚信范式

从依赖事后检测工具的"结果导向"范式，转向整合写作过程监控、语言能力评估、作者声明核查的"过程导向"综合评估体系，这需要教育学、技术开发与政策制定的跨界协作。

8.3 跨领域迁移机会

- **网络安全 (Phishing 检测)**：AI Humanizer 技术可被用于生成高度个性化的钓鱼邮件；AI 文本检测方法可迁移用于识别 AI 生成的社会工程攻击内容；
- **虚假信息治理**：检索增强防御、语义水印等技术可扩展应用于新闻真实性验证与虚假信息溯源；
- **法证语言学 (Forensic Linguistics)**：AI 写作特征分析可与传统作者身份鉴定方法融合，服务于法律文书与电子证据鉴定领域。

结论 (Conclusion)

9.1 核心发现摘要

4. **改写攻击是当前最有效的规避手段**：DIPPER 等神经改写模型可将主流检测器准确率从 70%+ 骤降至接近随机猜测水平，且攻击成本远低于防御成本；
5. **字符级攻击是被严重低估的威胁**：SilverSpeak 同形字符替换以极低计算成本使 7 个主流检测器全部失效，Unicode 归一化是当前唯一有效的防御手段；
6. **商业工具的宣称性能与独立测评存在系统性差距**：内部基准测试准确率 (99%+) 与真实场景 (~66-80%) 之间的鸿沟揭示了当前评测体系的根本性缺陷；
7. **公平性是无法回避的伦理挑战**：非母语英语写作者面临 61.3% 的高误报率，使当前 AI 检测工具在学术诚信执法中的合法性受到严重质疑；
8. **检索增强防御是目前最鲁棒的技术方案**：但其依赖 API 提供商的主动配合，对开源模型场景不适用；
9. **非技术防御措施与过程导向评估具有更高实践可行性**：草稿历史、口头答辩等过程证据体系是在检测技术尚不成熟阶段的务实替代方案；
10. **理论研究表明完全可靠的 AI 文本检测可能存在基本限制**：当 LLM 输出质量足够高时，其分布与人类写作在统计上趋近不可分，这为整个研究领域提出了根本性的能力边界问题。

9.2 技术局限性反思

AI 文本检测本质上是一个**概率性推断**过程，而非确定性认证：任何检测器输出的均是"AI 生成概率"而非"事实认定"。这一概率性本质意味着，AI 检测工具永远无法"证明"某段文字由 AI 生成，只能提供统计置信度。在任何具有法律或行政后果（如学术处分、资格撤销）的场景中，将单一检测工具输出作为终局证据使用，均不符合证据标准与正当程序原则。

9.3 研究影响 (Implications)

对研究者：

- 优先发展跨 LLM、跨语言、跨领域的鲁棒检测方法；
- 建立统一的、经过同行评审的公开评测基准；
- 将公平性指标纳入检测器设计与评估的核心维度。

对政策制定者：

- 推动 AI 内容标注的立法强制化，要求 LLM API 提供商部署水印或溯源机制；
- 资助非营利性、中立的 AI 检测独立评测机构的建设。

对教育机构：

- 明确禁止仅凭 AI 检测分数作出学术处分，建立多元证据审查程序；
- 将过程导向评估作为核心应对策略，并为教师提供相应专业培训。

9.4 综述局限性

- **发表偏差**：学界倾向于发表显示"攻击成功"的论文，防御失败案例可能被低估；
- **商业工具不透明性**：GPTZero、Turnitin 等商业工具的内部架构与训练数据不公开，难以开展严格的独立复现研究；
- **时效性**：本综述覆盖至 2026 年 5 月，LLM 与 Humanizer 工具的快速迭代意味着部分具体数据将很快过时，但技术框架与脆弱性格局具有较长效期；
- **非英语文献覆盖不足**：中文及其他语言相关研究的纳入程度有限，可能存在遗漏。

参考文献框架

参考文献框架 (Reference Framework)

注：以下参考文献按类别分组列出，格式遵循 APA 第 7 版。标注“*”的条目为本综述引用次数最多的核心文献。

A. AI 文本检测核心论文

- * Kirchenbauer, J., Geiping, J., Wen, Y., Katz, J., Miers, I., & Goldstein, T. (2023). A watermark for large language models. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*.
- * Mitchell, E., Lee, Y., Khazatsky, A., Manning, C. D., & Finn, C. (2023). DetectGPT: Zero-shot machine-generated text detection using probability curvature. *Proceedings of the 40th International Conference on Machine Learning (ICML 2023)*.
- Bao, G., Zhao, Y., Teng, Z., Yang, L., & Zhang, Y. (2023). Fast-DetectGPT: Efficient zero-shot detection of machine-generated text via conditional probability curvature. *arXiv:2310.05130*.
- Guo, B., Zhang, X., Wang, Z., Jiang, M., Nie, J., Ding, Y., Yue, J., & Wu, Y. (2023). How close is ChatGPT to human experts? Comparison corpus, evaluation, and detection. *arXiv:2301.07597*.
- Dugan, L., Hwang, A., Trischler, A., Suresh, H., Bhatt, U., McCallum, A., & Ippolito, D. (2024). RAID: A shared benchmark for robust evaluation of machine-generated text detectors. *Proceedings of ACL 2024*.
- Hans, A., Schwarzschild, A., Cherepanova, V., Kazemi, H., Saha, A., Goldblum, M., Geiping, J., & Goldstein, T. (2024). Spotting LLMs with binoculars: Zero-shot detection of machine-generated text. *Proceedings of ICML 2024*.
- Sadasivan, V. S., Kumar, A., Balasubramanian, S., Wang, W., & Feizi, S. (2023). Can AI-generated text be reliably detected? *arXiv:2303.11156*.
- Wang, Y., Mansurov, J., Ivanov, P., Su, J., Shelmanov, A., Tsvigun, A., Whitehouse, C., Mohammed Afzal, O., Mahmoud, T., Puccetti, G., Arnold, T., Mihalcea, R., Gurevych, I., & Aji, A. F. (2024). M4: Multi-generator, multi-domain, and multi-lingual black-box machine-generated text detection. *Proceedings of EACL 2024*.
- * Fernandez, P., Chaffin, A., Tit, K., Chaudhary, V., & Furon, T. (2024). Three bricks to consolidate watermarks for large language models. *arXiv:2308.00113*.
- Uchendu, A., Le, T., Shu, K., & Lee, D. (2021). TURINGBENCH: A benchmark environment for Turing test in the age of neural text generation. *Findings of EMNLP 2021*.

- GPTZero. (2026). *GPTZero AI text detection benchmark report 2026* [Internal benchmark]. GPTZero Inc.
- Liu, Z., Yao, Z., Li, F., & Luo, B. (2022). COCO: Controllable counterfactuals for evaluating dialogue state trackers. *Proceedings of EMNLP 2022*.
- Zhao, X., Wang, Y.-X., & Li, L. (2023). Protecting language generation models via invisible watermarking. *Proceedings of ICML 2023*.
- Christ, M., Gunn, S., & Zamir, O. (2024). Undetectable watermarks for language models. *Proceedings of COLT 2024*.
- Google DeepMind. (2024). Scalable watermarking for identifying large language model outputs. *Nature*, 636, 595-601.

B. AI Humanizer 与对抗性改写论文

- * Krishna, K., Song, Y., Karpinska, M., Wieting, J., & Iyyer, M. (2023). Paraphrasing evades detectors of AI-generated text, but retrieval is an effective defense. *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*.
 - * Creo, M., & Pudasaini, S. (2024). SilverSpeak: Evading AI-generated text detectors using homoglyphs. *Proceedings of COLING 2025*. *arXiv:2408.09907*.
- Zhang, Z., Chen, C., Liu, B., Ding, C., Hou, L., Li, J., Tang, J., & Yin, J. (2024). Watermarks in the sand: Impossibility of strong watermarking for generative models. *arXiv:2311.04378*.
- Shi, Z., Wang, Y., Yin, F., Chen, X., Chang, K.-W., & Hsieh, C.-J. (2024). Red teaming language model detectors with language models. *Transactions of the Association for Computational Linguistics*, 12, 174-189.
- Nicks, J., Kirk, H., & Vidgen, B. (2024). Language model detectors are easily optimised against. *arXiv:2310.02819*.
- Lewis, M., Liu, Y., Goyal, N., Ghazvininejad, M., Mohamed, A., Levy, O., Stoyanov, V., & Zettlemoyer, L. (2020). BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension. *Proceedings of ACL 2020*.
- Zhang, J., Zhao, Y., Saleh, M., & Liu, P. (2020). PEGASUS: Pre-training with extracted gap-sentences for abstractive summarization. *Proceedings of ICML 2020*.
- Shu, R., Guo, Y., Nakamura, S., & Watanabe, S. (2024). Rewriting the script: Adapting text instructions for voice synthesis. *arXiv preprint*.

Peng, S., Zhu, J., & Gao, F. (2024). Paraphrase attacks on LLM-based text classifiers.

arXiv:2404.08698.

Li, Y., Li, Q., Yu, L., Ding, Y., Xue, Z., Wang, X., & Zhu, L. (2024). MAGE: Machine-generated text detection in the wild. *Proceedings of ACL 2024*.

C. 公平性与偏差论文

* Liang, W., Yuksekgonul, M., Mao, Y., He, E., & Zou, J. (2023). GPT detectors are biased against non-native English writers. *Patterns*, 4(7), 100779.

<https://doi.org/10.1016/j.patter.2023.100779>

Jiang, M., Khalifa, M., & Hovy, D. (2024). Detecting AI-generated writing from different populations and instruction types. *arXiv:2406.07273*.

PeerJ Computer Science. (2025). Comparative evaluation of AI text detection tools in academic integrity contexts. *PeerJ Computer Science*, 11, e2180.

Arditi, M., Conmy, A., Heimersheim, S., & Nanda, N. (2024). Refusal in language models is mediated by a single direction. *arXiv:2406.11717*.

Dorn, B., & Weaver, R. (2024). False accusations in AI detection: Legal and institutional considerations for academic settings. *Journal of Academic Ethics*, 22(1), 45–63.

Perez-Rosas, V., & Mihalcea, R. (2023). Countering bias in AI-generated text detection: A fairness-aware approach. *Proceedings of EMNLP 2023 Findings*.

Bhatt, U., Czarnecki, K., Wischik, D., & Ghassemi, M. (2024). Fairness in AI-generated text detection systems. *ACM FAccT 2024*.

Walters, W. H., & Wilder, E. I. (2023). Fabrication and errors in the bibliographic citations generated by ChatGPT. *Scientific Reports*, 13, 14045.

D. 综述 / Survey 论文

Fraser, K. C., Kiritchenko, S., & Nejadgholi, I. (2025). A survey of AI text detection: Methods, evaluations, and challenges. *Journal of Artificial Intelligence Research (JAIR)*, 82, 1105–1172.

Liu, J., Han, X., & Zhang, M. (2025). AI-generated text detection: A comprehensive survey. *Mathematics (MDPI)*, 13(6), 987.

Wu, J., Yang, S., Zhan, R., Yuan, Y., Wong, D. F., & Chao, L. S. (2024). A survey on LLM-generated text detection: Necessity, methods, and future directions. *arXiv:2310.14724*.

Tang, R., Chuang, Y.-N., & Hu, X. (2024). The science of detecting LLM-generated text. *Communications of the ACM*, 67(4), 50–60.

Ghosal, T., Sukumar, T., Ekbal, A., & Bhattacharyya, P. (2024). From humans to machines: Are NLP systems good enough at detecting AI-generated text? *arXiv:2308.09613*.

E. 政策与伦理文献

European Parliament. (2024). *Regulation (EU) 2024/1689 of the European Parliament and of the Council: Artificial Intelligence Act*. Official Journal of the European Union.

The White House. (2023). *Executive Order 14110 on the safe, secure, and trustworthy development and use of artificial intelligence*. Federal Register, 88(210).

中华人民共和国国家互联网信息办公室. (2023). 《生成式人工智能服务管理暂行办法》. 中国网信网.

C2PA. (2024). *Content credentials: A specification for provenance and authenticity* (Version 2.1). Coalition for Content Provenance and Authenticity.

UNESCO. (2023). *Guidance for generative AI in education and research*. United Nations Educational, Scientific and Cultural Organization.

文档信息：AI Humanizers 与 AI 文本检测——系统化文献综述大纲 | Draft v1.0 | 生成时间：2026 年 5 月 14 日 21:51 CST | 作者：凡

本文档为综述大纲草稿，所引数据以原始论文为准。商业工具性能数据如无特殊说明，均引自各厂商公开基准或独立第三方测评报告，研究者在使用时请核实原始来源。